Развитие поддержки приближённых функциональных зависимостей в проекте “Desbordante”

Емельянов Максим Михайлович

Группа: *23.Б08-мм*
Кафедра: *кафедра информационно-аналитических систем*
Научный руководитель: *Чернышев Георгий Алексеевич*
Консультант: *ассистент кафедры информационно-аналитических систем, Чернышев Г. А.*
Номер семестра практики: *5*

1. Постановка задачи

Работа выполнялась в рамках проекта по наукоёмкому профилированию данных — “Desbordante”. Данная библиотека позволяет находить различные паттерны в данных, одним из известнейших из которых является функциональная зависимость (ФЗ). Различают точные и приближённые функциональные зависимости (ПФЗ); основная характеристика ПФЗ — метрика ошибки. Существует много видов метрик (например, g_1, $pdep$, FI), и от выбора метрики зависит результат работы алгоритмов поиска. Проблема заключается в том, что “Desbordante” поддерживает лишь малое количество метрик, а из-за специфичной структуры классов алгоритмы поиска ПФЗ возвращают их как точные ФЗ, вследствие чего невозможно узнать ошибку конкретного экземпляра ПФЗ.

Предыдущая работа была посвящена добавлению в проект модуля для упрощённого внедрения вычисления новых метрик [1]. Она послужила основой для расширения количества поддерживаемых метрик и последующей переработки структуры классов. Если предыдущая работа была сконцентрирована на создании инфраструктуры для вычисления метрик, то в данной работе основное внимание уделено рефакторингу иерархии классов для хранения ПФЗ с возможностью получения значения ошибки, а также интеграции с Python.

Целью работы является создание и внедрение новой иерархии классов и вспомогательных объектов для алгоритмов поиска ПФЗ, добавление новых метрик ошибки, реализация Python-привязок для разработанной системы и проверка работоспособности написанного кода.

Результаты работы направлены на расширение функциональности библиотеки Desbordante, что позволит пользователям (специалистам в области анализа данных) получать более детальную информацию о приближённых функциональных зависимостях, использовать различные метрики ошибки и интегрировать алгоритмы поиска ПФЗ в свои проекты через Python. В выполнении работы заинтересована команда проекта Desbordante, а также исследователи и инженеры, работающие с неполными или зашумлёнными данными (библиотека насчитывает более 100 тысяч загрузок).

2. Описание предлагаемого решения

Для реализации новой иерархии классов было принято решение разработать аналог уже существующей иерархии, но с хранением ПФЗ через новый объект данных `AFD`, в котором предусмотрено поле для ошибки и методы взаимодействия с этими зависимостями. Новая иерархия классов минимально отличается по интерфейсу от старой; такой подход позволил упростить последующую интеграцию в проект, где уже написаны алгоритмы, ориентированные на старую структуру.

После создания иерархии она была внедрена в уже существующий алгоритм `Tane` — замена прошла успешно, функциональность алгоритма сохранилась. Далее были написаны Python-привязки с использованием библиотеки `pybind11`, что даёт возможность вызывать алгоритмы, наследующие новую иерархию, из Python-среды. Также в модуль вычисления ошибки ПФЗ добавлены новые метрики (например, ρ, g_1, g_3), которые были реализованы и интегрированы в `Tane` для расширения его применимости.

Предложенное решение развивает ранее созданный модуль вычисления метрик ПФЗ и учитывает архитектуру существующей иерархии классов для точных ФЗ, что обеспечивает согласованность компонентов и упрощает дальнейшее расширение функциональности библиотеки.

3. Апробация

Апробация разработанных компонентов проводилась с помощью модульных тестов. Для проверки корректности работы новой иерархии классов были написаны новые тесты (8 тестов), использующие те же входные данные, что и тесты старой иерархии, поскольку новая система должна вести себя идентично старой за исключением возможности получать значение ошибки для каждого экземпляра ПФЗ. Новая иерархия успешно прошла все тесты, что подтвердило её работоспособность.

Для проверки корректности внедрения новой иерархии вместо старой в алгоритм `Tane` были адаптированы существовавшие ранее тесты для этого алгоритма (30 тестов). Тесты с прежними наборами данных показали, что алгоритм функционирует так же, как и до изменений, что подтверждает корректность замены.

Для проверки правильности вычисления новых метрик ошибки ПФЗ были добавлены соответствующие эталонные данные в уже существующие тесты (шесть дополнительных проверок). Все тесты выполняются успешно.

На данный момент код успешно проходит автоматическую сборку и тестирование в системе непрерывной интеграции (CI/CD) и ожидает рецензирования (code review) участниками команды.

4. Заключение

В ходе выполнения работы получены следующие результаты:

- Реализована новая иерархия классов для алгоритмов поиска приближённых функциональных зависимостей;
- Добавлены новые метрики в модуль вычисления ошибки для ПФЗ;

[1] Результат предыдущей работы доступен по ссылке: `https://github.com/Desbordante/desbordante-core/pull/614`

- Написаны тесты для вышеперечисленных нововведений;
- Реализованы Python-привязки для новой иерархии классов.

Ссылка на пуллреквест: `https://github.com/Desbordante/desbordante-core/pull/688`.

В настоящий момент решение находится на ревью, ожидаются замечания по технической реализации. После прохождения ревью изменения будут включены в основную ветку проекта.