

Санкт-Петербургский государственный университет

Кафедра информационно-аналитических систем

Группа 24.Б42-мм

Разработка и интеграция новых методов базового статистического профилирования в Desbordante

Березикова Полина Сергеевна

Отчёт по учебной практике
в форме «Решение»

Научный руководитель:
асс. кафедры ИАС Г. А. Чернышев

Санкт-Петербург
2026

Оглавление

Введение	3
1. Постановка задачи	4
2. Обзор	5
3. Описание решения	7
3.1. Корреляции	7
3.2. Архитектурные особенности реализации	10
3.3. Rybind11	11
3.4. Тестирование	12
4. Эксперимент	13
4.1. Исследовательские вопросы	13
4.2. Условия эксперимента	13
4.3. Результаты	14
4.4. Анализ результатов	15
4.5. Выводы	16
Итоговая таблица статистик	18
Заключение	22
Список литературы	23

Введение

Профилирование данных [3] — процесс систематического анализа, исследования и оценки наборов данных для получения их метаданных. С помощью полученной информации можно оценить качество данных и их пригодность для дальнейшей обработки.

Профилирование данных бывает наукоёмким и простым. Наукоёмкое профилирование заключается в поиске функциональных и скрытых зависимостей, а простое включает в себя вычисление статистических характеристик, таких как количество строк и столбцов, средние значения, медианы, а также более сложные меры, описывающие закономерности между колонками.

Desbordante [4] — высокопроизводительный профилировщик с открытым исходным кодом, разрабатываемый на языке C++ с 2019 года. Он предоставляет широкий набор инструментов как для наукоёмкого, так и для простого профилирования. Однако в Desbordante отсутствуют корреляции, оценивающие статистическую связь между колонками. Такие корреляции широко используются в анализе данных для проверки гипотез, отбора признаков и обнаружения коллинеарности.

Данная работа направлена на расширение функциональности Desbordante за счёт добавления коэффициентов связи между колонками табличных данных, что позволит выполнять более глубокий анализ, выявляя не только одномерные характеристики, но и статистические связи между колонками. Таким образом, Desbordante станет более универсальным инструментом для профилирования данных.

1. Постановка задачи

К началу данной работы в Desbordante уже был реализован ряд простых статистик. Предыдущие работы по расширению набора статистик в Desbordante обеспечили вычисление широкого спектра одномерных характеристик — от классических (среднее, медиана, реализованных в работе Михаила Фирсова [11]) до более сложных (энтропия Шеннона, коэффициент Джини, реализованных в работе Дмитрия Виноградова [9]). Однако все эти статистики описывают только отдельные колонки и не позволяют анализировать связи между ними.

Целью данной работы является реализация корреляционных коэффициентов и добавление их в Python-интерфейс Desbordante с помощью `pybind11`. Для достижения цели были поставлены следующие задачи:

1. Реализовать на C++ методы для вычисления корреляций;
2. Создать Python-привязки;
3. Написать модульные тесты для C++ и Python;
4. Провести оценку производительности реализованных корреляций.

2. Обзор

В данный момент существует множество инструментов, поддерживающих вычисление корреляций. Наиболее распространенными являются библиотеки языка Python — `pandas` и `scipy`, а также профилировщики данных, такие как `ydata-profiling`.

- `Pandas` [7] — библиотека с открытым исходным кодом, предоставляющая высокопроизводительные структуры данных и инструменты анализа данных для языка программирования Python. Разработана компанией NumFOCUS, распространяется под свободной лицензией BSD. `Pandas` построена на основе `NumPy` и предназначена для удобной интеграции в среду научных вычислений. Для вычисления корреляций используется метод `DataFrame.corr()`, который применяется к объекту `DataFrame` и возвращает матрицу парных коэффициентов для всех числовых колонок. С помощью аргумента `method` можно выбрать способ вычисления корреляции: коэффициент Пирсона, Спирмена или Кендалла.
- `SciPy` [6] — библиотека с открытым исходным кодом для языка программирования Python, предназначенная для научных и инженерных расчетов. Разрабатывается и поддерживается публично на GitHub, распространяется под лицензией BSD. В `SciPy` входит модуль `scipy.stats`, содержащий множество функций для статистического анализа данных. В отличие от `Pandas`, `SciPy` работает с парами переменных. В набор функций входят так же коэффициенты Пирсона, Спирмена и Кендалла. Инструмент для вычисления корреляционного коэффициента Крамера отсутствует, но модуль предоставляет функцию `chi2_contingency`, позволяющую рассчитать χ^2 -статистику по таблице сопряженности, на основе которой можно найти коэффициент Крамера.
- `ydata-profiling` [8] — open-source библиотека для автоматизации анализа данных, распространяемая под свободной лицензией MIT. Библиотека предоставляет комплексный отчет по анализу набора

данных, в который входит вычисление четырех классических корреляционных коэффициентов.

Чтобы не уступать в функциональности популярным инструментам для анализа данных, есть необходимость в реализации таких важных статистик как корреляционные коэффициенты.

3. Описание решения

3.1. Корреляции

В ходе работы были реализованы следующие функции, позволяющие вычислить корреляционные коэффициенты:

- **GetPearsonCorrelation:** Коэффициент корреляции Пирсона [5] анализирует числовые значения и выявляет силу и направление линейной зависимости. Знак коэффициента показывает направление зависимости: положительные значения соответствуют прямой зависимости, при которой увеличение одной переменной сопровождается увеличением другой, а отрицательные — обратной зависимости. Абсолютное значение коэффициента характеризует силу линейной связи: значения, близкие к 0, указывают на отсутствие линейной зависимости, а значения, близкие к 1 или -1 — на сильную зависимость. При этом коэффициент Пирсона чувствителен к выбросам и предполагает работу с числовыми данными, между которыми ожидается строго прямая или обратная зависимость. Поэтому в случаях, когда зависимость между переменными имеет нелинейный характер, даже при сохранении монотонности, коэффициент Пирсона может принимать значения, близкие к нулю, несмотря на наличие статистической связи. Коэффициент Пирсона (r) вычисляется по формуле

$$r_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

где:

x_i, y_i — отдельные значения переменных в выборке;

$\bar{x}, \bar{y}$ — средние арифметические соответствующих переменных.

- **GetSpearmanCorrelation:** Коэффициент корреляции Спирмена [1] использует переход от абсолютных значений к их рангам — порядковым номерам. Для обработки одинаковых значений вычисляется средний ранг. Благодаря системе рангов коэффициент

Спирмена менее чувствителен к выбросам. Измеряет степень, с которой отношение между двумя переменными может быть описано как монотонная функция. Если повышение значения одной переменной неизменно сопровождается повышением (или неизменно понижением) значения другой, то связь считается монотонной, даже если она нелинейна. Таким образом, коэффициент Спирмена можно рассматривать как более универсальную альтернативу коэффициенту Пирсона для данных, не удовлетворяющих предположению о линейности. Коэффициент корреляции Спирмена (ρ) находится по формуле:

$$\rho = \frac{\sum_{i=1}^n (r_{x_i} - \bar{r}_x)^2 + \sum_{i=1}^n (r_{y_i} - \bar{r}_y)^2 - \sum_{i=1}^n d_i^2}{2\sqrt{(\sum_{i=1}^n (r_{x_i} - \bar{r}_x)^2) \cdot (\sum_{i=1}^n (r_{y_i} - \bar{r}_y)^2)}}$$

где:

r_{x_i}, r_{y_i} — ранги значений в первой и второй переменных;

$\bar{r}_x, \bar{r}_y$ — средние ранги соответствующих переменных;

$d_i = r_{x_i} - r_{y_i}$ — разность рангов для i -го наблюдения;

n — объём выборки.

- **GetKendallCorrelation:** Коэффициент корреляции Кендалла [10] измеряет порядковую связь между двумя переменными на основе подсчёта согласованных и несогласованных пар наблюдений. Пара считается согласованной, если ранги обеих переменных изменяются в одном направлении (т.е. при $x_i > x_j$ и $y_i > y_j$ или $x_i < x_j$ и $y_i < y_j$), и несогласованной — если в противоположных. Если ранги не различаются, то эти пары игнорируются. По сравнению со Спирменом коэффициент Кендалла (τ) более устойчив при небольших объёмах данных, однако его вычисление требует анализа всех пар наблюдений, что делает его более вычислительно затратным. Формула для расчета:

$$\tau = \frac{C - D}{\frac{n(n-1)}{2}} = \frac{C - D}{C + D}$$

где:

C — количество согласованных пар;
 D — количество несогласованных пар;
 n — количество наблюдений.

- **GetCramersVCorrelation:** Коэффициент Крамера [2] измеряет связь между двумя категориальными переменными и принимает значения в диапазоне $[0, 1]$ (0 — отсутствие связи, 1 — полная зависимость). Вычисляется на основе таблицы сопряженности и статистики χ^2 . Таблица сопряженности представляет собой матрицу частот, где строки соответствуют категориям одной переменной, а столбцы — категориям другой. Каждая ячейка таблицы содержит количество наблюдений для конкретной комбинации категорий. На основе этой таблицы вычисляется статистика χ^2 , позволяющая оценить отклонение наблюдаемого распределения от ожидаемого при условии независимости переменных. В отличие от коэффициентов Пирсона, Спирмена и Кендалла, коэффициент Крамера (V) предназначен исключительно для категориальных данных и не отражает направление зависимости, а лишь степень связи между признаками. Формулы для вычисления:

$$V = \sqrt{\frac{\chi^2}{n \cdot \min(r - 1, c - 1)}}, \quad \chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(n_{ij} - E_{ij})^2}{E_{ij}}, \quad E_{ij} = \frac{R_i \cdot C_j}{n}$$

где:

r — количество строк (уникальных значений первой переменной);
 c — количество столбцов (уникальных значений второй переменной);
 n — общее количество наблюдений;
 n_{ij} — наблюдаемая частота в ячейке;
 E_{ij} — ожидаемая частота при условии независимости;
 R_i — сумма наблюдений в i -й строке;
 C_j — сумма наблюдений в j -м столбце.

Рассмотренные коэффициенты корреляции ориентированы на разные типы данных и разные виды зависимостей, поэтому не являются

взаимозаменяемыми. Коэффициент Пирсона применяется для поиска линейной зависимости между числовыми признаками. Коэффициенты Спирмена и Кендалла являются ранговыми и используются в случаях, когда зависимость может быть монотонной, но не обязательно линейной. При этом коэффициент Спирмена можно рассматривать как ранговое расширение идеи Пирсона, поскольку после преобразования значений в ранги вычисление фактически выполняется аналогичным образом. Коэффициент Кендалла отличается подходом к оценке зависимости и основывается на сравнении пар наблюдений. Коэффициент Крамера занимает отдельную нишу, так как применяется для категориальных признаков и основан на анализе таблицы сопряжённости. Таким образом, каждая из реализованных корреляций имеет собственную область применения: числовые линейные данные, ранговые зависимости или категориальные признаки. Реализация всех четырёх коэффициентов позволяет сделать профилирование данных в Desbordante более универсальным и применимым к различным типам наборов данных.

3.2. Архитектурные особенности реализации

При разработке методов корреляций были реализованы два ключевых механизма, обеспечивающих корректность и производительность вычислений: обработка связанных рангов для коэффициента Спирмена и кэширование результатов для всех четырёх методов.

Коэффициент ранговой корреляции Спирмена требует преобразования исходных числовых значений в ранги. В случае присутствия одинаковых значений (связей) стандартный подход, при котором каждому значению присваивается уникальный ранг, становится некорректным.

Для решения этой проблемы была реализована функция `GetRanks`, которая выполняет следующие действия:

1. Сортирует значения и сохраняет их исходные индексы;
2. Обходит отсортированный массив, выделяя группы одинаковых значений;

3. Присваивает каждому значению в группе средний арифметический ранг.

В Desbordante изначально существовал веб-интерфейс, при навигации в котором пользователь мог многократно покидать и возвращаться на страницу с результатами профилирования. Чтобы избежать повторного выполнения одних и тех же вычислений при каждом возврате, был реализован механизм кэширования результатов.

В настоящее время веб-интерфейс не поддерживается, однако механизм кэширования сохранился в системе и оказался полезным для других сценариев использования.

В данной работе также была реализована система кэширования результатов. Каждая корреляция имеет собственный кэш на основе `std::map` с ключом $(\min(i, j), \max(i, j))$. Перед вычислением метод `GetOrCalculateCorrelation` проверяет наличие результата в кэше. Очистка кэша происходит при загрузке новой таблицы.

3.3. Pybind11

Для обеспечения доступа к реализованным корреляционным мерам из языка Python применяется библиотека `pybind11`. Она обеспечивает автоматическое преобразование типов, поддержку исключений и интеграцию с шаблонами C++.

В ходе работы для каждого из четырёх корреляционных методов была добавлена соответствующая привязка в файл `bind_statistics.cpp`:

```
.def("get_pearson_correlation", &DataStats::GetPearsonCorrelation,
     "Returns the Pearson correlation coefficient")
.def("get_spearman_correlation", &DataStats::GetSpearmanCorrelation,
     "Returns the Spearman's rank correlation coefficient")
.def("get_kendall_correlation", &DataStats::GetKendallCorrelation,
     "Returns the Kendall's tau correlation coefficient")
.def("get_cramers_v_correlation", &DataStats::GetCramersVCorrelation,
     "Returns the Cramer's V statistic")
```

3.4. Тестирование

Для проверки корректности реализованных корреляций были разработаны модульные тесты на языках C++ и Python, где сравнивается результат работы методов с эталонными значениями, посчитанными с помощью библиотеки SciPy. Тестирование проводилось на наборе данных TestDataStats.csv, который содержит колонки различных типов: числовые, строковые, смешанные, а также NULL.

Тесты на C++ реализованы с использованием фреймворка Google Test. Каждый метод проверяется на корректность (happy path) и равенство результатов при симметричной смене аргументов. Кроме того, проверяется, что повторный вызов метода с теми же аргументами возвращает значение из кэша, идентичное первому результату.

Для каждой корреляции был произведён выбор корректных колонок из набора данных TestDataStats.csv: числовые колонки (2, 7) — для коэффициентов Пирсона, Спирмена и Кендалла; категориальные колонки (5, 10) — для Крамера.

Для каждого из четырёх коэффициентов корреляции были реализованы три модульных теста: тест на корректность вычисления, тест на независимость результата от порядка переданных колонок и тест на повторное получение значения из кэша. Всего было разработано 12 тестов.

Для проверки корректности работы Python-привязок (pybind11) были разработаны тесты с использованием стандартного модуля unittest.

4. Эксперимент

Для оценки времени выполнения реализованных корреляций был проведен эксперимент, в ходе которого была проанализирована скорость вычисления коэффициентов корреляций в зависимости от количества данных.

4.1. Исследовательские вопросы

Для проведения оценки были сформулированы следующие вопросы:

- **RQ1:** сколько времени требуется для вычисления каждой корреляции на наборе данных в один миллион строк;
- **RQ2:** как изменяется время выполнения при увеличении объёма данных;
- **RQ3:** насколько кэширование ускоряет время повторного вычисления корреляции.

4.2. Условия эксперимента

Эксперимент проводился на наборе данных `iowa1kk.csv`, содержащем один миллион строк и 24 столбца. Для каждого размера данных (100k, 200k, 400k, 600k, 1000k строк) производилось по 5 замеров времени выполнения каждой корреляции, после чего вычислялось среднее значение. Измерялось только время вычисления корреляции, без учёта загрузки данных.

Из-за квадратичной сложности алгоритма время вычисления коэффициента Кендалла при количестве строк, большего 400 тысяч, превышало 2 минуты с учётом загрузки данных, что было признано неприемлемым для эксперимента, и замеры были остановлены.

4.3. Результаты

В таблице 1 представлены результаты замеров времени вычисления реализованных корреляций.

Таблица 1: Время вычисления корреляций (мс)

Размер (тыс.)	Пирсон ($O(n)$)	Спирмен ($O(n \log n)$)	Кендалл ($O(n^2)$)	Крамер ($O(n)$)
100	14	11	284	67
200	31	35	1145	129
400	59	71	4672	308
600	84	101	-	381
800	108	135	-	410
1000	135	216	-	447

На рисунке 1 представлен график зависимости времени вычисления корреляций от объёма данных.




Рис. 1: Зависимость времени вычисления корреляций от объёма данных.

4.4. Анализ результатов

RQ1: Сколько времени требуется для вычисления каждой корреляции? Приведённые в таблице 1 значения представляют собой среднее время выполнения корреляционных алгоритмов без учёта времени загрузки данных. Время парсинга CSV-файла и построения внутренних структур данных исключаются из итоговых значений, что позволяет оценить исключительно вычислительную сложность самих корреляционных мер.

На наборе данных из одного миллиона строк:

- Коэффициент Пирсона: ≈ 135 мс;
- Коэффициент Спирмена: ≈ 216 мс;
- Коэффициент Крамера: ≈ 447 мс;
- Коэффициент Кендалла: время выполнения на 400 тысячах строк составило ≈ 4.7 секунды. При попытке вычисления на большем объёме данных время превысило установленный лимит в 2 минуты ввиду загрузки данных, поэтому дальнейшие замеры для Кендалла не производились.

RQ2: Как изменяется время выполнения при увеличении объёма данных?

Анализ полученных зависимостей позволяет сделать следующие выводы:

- Коэффициент Пирсона демонстрирует линейный рост времени выполнения, что соответствует однократному проходу по данным для вычисления средних значений и суммы произведений отклонений.
- Коэффициент Спирмена показывает рост времени, близкий к линейному, что обусловлено необходимостью сортировки значений для присвоения рангов. Логарифмический множитель вносит заметный вклад лишь при очень больших объёмах данных.

- Коэффициент Кендалла подтверждает квадратичный характер зависимости, что объясняется попарным сравнением всех элементов выборки. Уже на 200 тысячах строк время вычисления превышает 1 секунду, а на 400 тысячах достигает примерно 4.7 секунды.
- Коэффициент Крамера демонстрирует в целом линейный рост времени. Отклонения от строгой линейности связаны с тем, что вычислительная сложность данного коэффициента зависит не только от количества строк, но и от числа уникальных значений в категориальных колонках, определяющего размер таблицы сопряжённости.

RQ3: Насколько кэширование ускоряет время повторного вычисления корреляции? Важной особенностью реализации является кэширование результатов вычисления корреляций. При повторном запросе коэффициента для той же пары колонок результат возвращается из кэша:

Первый вызов (вычисление, Пирсон на 1 млн строк): 135 мс
 Второй вызов (из кэша): 0.01 мс

Таким образом, кэширование позволяет получить результат более чем в 10 тысяч раз быстрее по сравнению с полным пересчётом. Для корреляций, требующих больше времени для вычислений, разница во времени между первым и повторным вызовами оказывается ещё более существенной.

Это особенно важно, когда пользователь многократно запрашивает корреляции между одними и теми же парами колонок. Реализованное кэширование позволяет при повторном запросе возвращать результат из кэша без повторного пересчёта.

4.5. Выводы

Экспериментальное исследование подтвердило:

- Приемлемую производительность для практического использования на наборе данных до 1 миллиона строк;
- Эффективность кэширования.

Итоговая таблица статистик

В таблице 2 используются следующие обозначения:

- + — полная реализация;
- — — реализация отсутствует;
- + — полная реализация, выполненная в рамках работы.

Таблица 2: Поддерживаемые статистики

Тип статистики	Статистика	C++	Python
String	vocab	+	+
	words	+	+
	topKChars	+	+
	topKWords	+	+
	minWords	+	+
	maxWords	+	+
	wordCount	+	+
	nonLetterChars	+	+
	diacriticChars	+	+
	digitChars	+	+
	lowercaseChars	+	+
	uppercaseChars	+	+
	ExclFirstLetters	—	—
	minWhiteSpaces	+	+
	maxWhiteSpaces	+	+
	avgChars	+	+
	minChars	+	+
	maxChars	+	+
	totalCharCount	+	+
	entirelyLowercaseCount	+	+
	entirelyUppercaseCount	+	+

	entropy	+	+
	gini_coefficient	+	+
	firstCharFrequency	+	+
	lastCharFrequency	+	+
	leadingWhitespaceCount	+	+
	trailingWhitespaceCount	+	+
	specialCharsCount	+	+
General	dataType	+	+
	columnName	+	+
	categorical	+	+
	samples	+	+
	min	+	+
	max	+	+
	quantiles	+	+
	nullCount	+	+
	uniqueCount	+	+
	sampleSize	+	+
	categoricalCount	—	—
	uniqueRatio	—	—
	categories	+	+
	defaultValueCount	—	—
	distinctCount	—	—
	absentProperty	—	—
	whiteSpaceOnlyCount	+	+
	precision	—	—
	sampleRatio	—	—
	highestTime	—	—
	lowestTime	—	—
	sum	+	+
	mean	+	+
	median	+	+
	geometricMean	+	+

	variance	+	+
	correctedSTD	+	+
	centralMoment	+	+
	standardizedCentralMoment	+	+
	skewness	+	+
	kurtosis	+	+
	meanAbsoluteDeviation	+	+
	medianAbsoluteDeviation	+	+
	numZeros	+	+
	numNegatives	+	+
	biasCorrection	-	-
	histogram	-	-
	histogramAndQuantiles	-	-
	interquartile_range	+	+
	coefficient_of_variation	+	+
	sumOfSquares	+	+
	zero%	+	+
Bool	trueCount	+	+
	falseCount	+	+
Tableau	columnCount	+	+
	rowHasNullRatio	+	+
	rowIsNullRatio	+	+
	uniqueRowRatio	+	+
	duplicateRowCount	-	-
	fileType	-	-
	encoding	-	-
	correctionMatrix	-	-
	chi2Matrix	-	-
	profileSchema	-	-
Ordered	monotonicity_flags	+	+
Correlations	GetPearsonCorrelation	+	+
	GetSpearmanCorrelation	+	+

	GetKendallCorrelation	+	+
	GetCramersVCorrelation	+	+

Заключение

В ходе выполнения работы были реализованы и интегрированы в Desbordante четыре коэффициента корреляции: Пирсона, Спирмена, Кендалла и Крамера.

Основные результаты работы:

1. Реализованы методы на C++ с использованием кэширования;
2. Созданы Python-привязки через pybind11;
3. Написаны модульные тесты для C++ и Python;
4. Проведена экспериментальная оценка производительности.

Разработанные методы расширяют возможности Desbordante, позволяя выявлять статистические связи между колонками данных, что необходимо для комплексного профилирования и оценки качества данных.

Все поставленные задачи выполнены, код принят в основной репозиторий проекта Desbordante¹.

¹Pull request #733: <https://github.com/Desbordante/desbordante-core/pull/733>

Список литературы

- [1] Chen Peter Y., Popovich Paula M. Spearman Correlation Coefficient // The SAGE Encyclopedia of Social Science Research Methods. — Thousand Oaks, CA : SAGE Publications, 2011. — URL: <https://methods.sagepub.com/ency/edvol/the-sage-encyclopedia-of-social-science-research-methods/chpt/spearman-correlation-coefficient> (дата обращения: 2026-04-10).
- [2] Cramér Harald. Mathematical Methods of Statistics. — Princeton : Princeton University Press, 1946. — P. 575. — URL: <https://archive.org/details/in.ernet.dli.2015.149716> (дата обращения: 2026-04-11).
- [3] [Data Profiling](#) / Ziawasch Abedjan, Lukasz Golab, Felix Naumann, Thorsten Papenbrock. Synthesis Lectures on Data Management. — Morgan & Claypool Publishers, 2018. — ISBN: [978-3-031-00737-8](#). — URL: <https://doi.org/10.2200/S00878ED1V01Y201810DTM052>.
- [4] [Desbordante: from benchmarking suite to high-performance science-intensive data profiler](#) / George Chernishev, Michael Polyntsov, Anton Chizhov et al. // Proceedings of the 8th International Conference on Data Science and Management of Data (12th ACM IKDD CODS and 30th COMAD). — CODS-COMAD '24. — New York, NY, USA : Association for Computing Machinery, 2025. — P. 234–243. — URL: <https://doi.org/10.1145/3703323.3703725>.
- [5] SAGE Publications. Correlation // Encyclopedia of Research Design. — Thousand Oaks, CA : SAGE Publications, 2012. — URL: <https://methods.sagepub.com/ency/edvol/encyc-of-research-design/chpt/correlation> (дата обращения: 2026-04-09).
- [6] SciPy Developers. SciPy: Fundamental Algorithms for Scientific

- Computing in Python. — 2024. — URL: <https://scipy.org/> (дата обращения: 2026-04-08).
- [7] The Pandas Development Team. pandas: powerful Python data analysis toolkit. — 2023. — URL: <https://pandas.pydata.org/> (дата обращения: 2026-04-08).
- [8] YData Profiling contributors. ydata-profiling: Exploratory Data Analysis for Python. — 2025. — URL: <https://github.com/ydataai/ydata-profiling> (дата обращения: 2026-04-08).
- [9] Виноградов Дмитрий. Расширение набора простых статистик в Desbordante. — 2026. — URL: <https://github.com/Desbordante/desbordante-core/blob/main/docs/papers/Statistics%20-%20Vinogradov%20Dmitri%20-%202025%20autumn.pdf>.
- [10] Гмурман Владимир Ефимович. Руководство к решению задач по теории вероятностей и математической статистике. — 9-е, стереотипное изд. — Москва : Высшая школа, 2004. — С. 201–205. — ISBN: 5-06-004212-X. — URL: https://www.nntu.ru/frontend/web/ngtu/files/org_structuralibrary/resurvsy/pervokursnik/its/matem/osnovn/2.pdf (дата обращения: 2026-04-09).
- [11] Фирсов Михаил. Реализация статистик Desbordante. — 2025. — URL: <https://github.com/Desbordante/desbordante-core/blob/main/docs/papers/Statistics%20-%20Mikhail%20Firsov%20-%202022%20autumn.pdf>.