

Санкт-Петербургский государственный университет

Кафедра, информационно-аналитических систем

Группа 24.Б42-мм

Расширение набора простых статистик в “Desbordante”

Виноградов Дмитрий Валентинович

Отчёт по учебной практике
в форме «Решение»

Научный руководитель:
асс. кафедры ИАС Г. А. Чернышев

Санкт-Петербург
2026

Оглавление

Введение	3
1. Постановка задачи	5
2. Обзор	6
2.1. Статистики	6
2.2. Аналоги	8
3. Реализация	10
4. Эксперимент	13
4.1. Исследовательские вопросы	13
4.2. Условия эксперимента	13
4.3. Тестовые данные	13
4.4. Результаты	14
4.5. Выводы	15
Итоговая таблица статистик	16
Заключение	20
Список литературы	21

Введение

Профилирование данных представляет собой процесс исследования наборов данных, направленный на извлечение метаданных и оценку качества данных. “Метаданные” — это любые данные о самих данных, т.е. любая информация, что-то говорящая об оригинальном массиве данных. В современных условиях, когда объемы данных экспоненциально растут, автоматизированный анализ их качества становится критически важным для обеспечения достоверности принимаемых решений.

Ключевые задачи профилирования данных включают:

- Сбор базовых атрибутов: имя файла, тип данных, размер, кодировка
- Выявление скрытых закономерностей и зависимостей между полями
- Диагностику проблем данных: пропущенные значения, аномалии, нарушение целостности
- Генерацию описательной статистики для числовых и категориальных полей

В современной практике выделяют два основных подхода к профилированию:

- **Простое (базовое) профилирование:** генерация описательной статистики (среднее, медиана, квартили, стандартное отклонение), количественные и качественные показатели (количество строк, столбцов, уникальных значений)
- **Наукоемкое (углубленное) профилирование:** обнаружение функциональных зависимостей, ассоциативных правил и других нетривиальных паттернов в данных

Desbordante [3] — это профилировщик данных с открытым исходным кодом, разрабатываемый с 2019 года на языке C++.

Данная работа является продолжением усилий по расширению функциональности Desbordante и направлена на реализацию дополнительных статистик табличных данных.

1. Постановка задачи

Настоящая работа выполняется в контексте продолжающегося развития проекта Desbordante. К моменту начала работы уже был выполнен значительный объем работ по расширению его функциональности:

- **Михаил Фирсов** провел комплексный обзор существующих профилировщиков данных и реализованных в них простых статистик, после чего интегрировал часть этих статистик в ядро Desbordante [12].
- **Павел Аносов** продолжил эту работу и, используя библиотеку pybind11, создал Python-интерфейс для доступа к реализованным статистикам [10].
- **Игорь Коробицын** выполнил аналогичную работу по расширению функционала системы [11].

Основная цель настоящей работы — дальнейшее расширение набора простых статистик в профилировщике Desbordante с обязательным обеспечением доступа к ним через Python-интерфейс. Это позволит пользователям анализировать данные более комплексно и получать дополнительные метрики качества без переключения между различными инструментами.

Для достижения поставленной цели необходимо решить следующие задачи:

1. Выбрать и интегрировать в ядро Desbordante новые статистики;
2. Создать модульные тесты для проверки корректности реализации алгоритмов;
3. Используя библиотеку pybind11, обеспечить доступ к новым статистикам из Python-окружения;
4. Провести сравнительный эксперимент среди аналогов.

2. Обзор

2.1. Статистики

В ходе исследования было обнаружена необходимость в следующих статистиках:

1. Межквартильный размах

Формула: $IQR = Q_3 - Q_1$

- Q_1 — первый квартиль (25-й перцентиль)
- Q_3 — третий квартиль (75-й перцентиль)

Показывает разброс средних 50% данных, исключая выбросы т.е. позволяет определить типичный диапазон значений в данных.

2. Коэффициент вариации

Формула: $CV = \frac{\sigma}{\mu}$

- σ — стандартное отклонение выборки (с поправкой Бесселя)
- μ — среднее арифметическое выборки

Измеряет, насколько данные разбросаны относительно среднего в процентах.

3. Статистика теста Харке-Бера

Формула: $JB = \frac{n}{6} \left(S^2 + \frac{(K - 3)^2}{4} \right)$

- n — объём выборки
- S — коэффициент асимметрии
- K — коэффициент эксцесса

Показывает, насколько распределение данных отличается от нормального, учитывая как асимметрию, так и эксцесс распределения.

4. Монотонность последовательности

Определение: последовательность x_1, x_2, \dots, x_n является

- **ascending** — если $x_i \leq x_{i+1}$ для всех i (неубывающая)
- **descending** — если $x_i \geq x_{i+1}$ для всех i (невозрастающая)
- **equal** — если все элементы равны
- **none** — если ни одно из условий выше не выполняется

Определяет характер упорядоченности: возрастание, убывание или отсутствие монотонности. учитывая NULL-значения, пропуская их при анализе.

5. Энтропия Шеннона

Формула: $H = - \sum_{i=1}^m p_i \log_2 p_i$

- m — количество уникальных значений в выборке
- p_i — вероятность i -го уникального значения, $p_i = \frac{n_i}{n}$
- n_i — частота i -го уникального значения
- n — общий объём выборки

Показывает, насколько разнообразны значения в выборке

6. Коэффициент Джини

Формула: $G = 1 - \sum_{i=1}^m p_i^2$

- m — количество уникальных значений в выборке

- p_i — вероятность i -го уникального значения, $p_i = \frac{n_i}{n}$
- G — коэффициент Джини в диапазоне $[0, 1]$
- n_i — частота i -го уникального значения
- n — общий объём выборки

Показывает, сконцентрированы ли данные вокруг одного-двух значений или равномерно распределены между многими вариантами. Является более простой альтернативой энтропии для оценки разнообразия.

2.2. Аналоги

Pandas [8] и **Pandas Profiling** [9]: поддерживают расчет IQR и коэффициента вариации, однако реализация не оптимизирована и требует полной загрузки данных в память при каждом вызове функции. Коэффициент Джини отсутствуют в базовом функционале, их расчет требует написания дополнительного кода.

AutoViz [1]: основное внимание уделяется автоматической визуализации, поэтому предоставляет лишь базовый набор статистик, таких как среднее и медиана. IQR и коэффициент вариации могут быть получены косвенно через визуализации (например, box plot), но не в виде точных числовых метрик. Тест Харке-Бера, проверка монотонности, энтропия и коэффициент Джини не реализованы.

OpenClean [4]: библиотека ориентирована на задачи очистки данных, поэтому ее возможности профилирования ограничены. Монотонность, тест Харке-Бера и коэффициент Джини не поддерживаются.

DataExplorer [2] (для R): похож на Pandas по функциональности. Тест Харке-Бера доступен через дополнительные пакеты, но не входит в базовый набор. Проверка монотонности и коэффициент Джини отсутствуют.

Metanome [6, 7]: специализируется на обнаружении зависимостей в данных (например, функциональных), а не на описательной статистике.

Поэтому такие метрики, как IQR, коэффициент вариации, тест Харке-Бера, энтропия и коэффициент Джини, не реализованы. Фокус сделан на алгоритмах поиска паттернов, а не на статистических агрегатах.

SPSS [5]: как профессиональный статистический пакет, поддерживает все указанные статистики. Однако этот продукт коммерческий т.е. платный.

Excel / LibreOffice Calc: базовые статистики, включая квантили для IQR и коэффициент вариации, доступны. Однако расчеты требуют ручного составления формул, что подвержено ошибкам. Тест Харке-Бера, проверка монотонности, энтропия и коэффициент Джини требуют сложных макросов (набор команд или действий).

Таким образом, ни один из рассмотренных некоммерческих профайлеров не предоставляет полного набора требуемых статистик в едином интерфейсе. Реализации, где они присутствуют, часто страдают от недостаточной производительности или зависимости от сторонних библиотек.

3. Реализация

Архитектурные решения

В проекте `Desbordante` уже были реализованы эффективные механизмы оптимизации производительности, которые я использовал при добавлении новых статистик:

Таблица 1: Использованные механизмы оптимизации

Механизм	Использование в новых статистиках
Кэширование результатов	Все статистики сохраняются в структуре <code>ColumnStats</code> после первого вычисления
Использование вычисленных значений	IQR использует квартили, CV использует стандартное отклонение и среднее
Ленивые вычисления	Статистики вычисляются только при первом вызове соответствующих методов
Оптимизация памяти	Временные объекты освобождаются сразу после использования

Детали реализации

Межквартильный размах (IQR)

Использует уже вычисленные квартили Q_1 и Q_3 из структуры `ColumnStats`. Формула: $IQR = Q_3 - Q_1$. Обрабатывает краевые случаи: пустые данные, некорректные типы.

Коэффициент вариации (CV)

Использует предварительно вычисленные стандартное отклонение и среднее значение. Формула: $CV = \frac{\sigma}{\mu}$. Проверяет условие $\mu \neq 0$, иначе возвращает пустое значение.

Монотонность

Анализирует последовательность значений за один проход и определяет состояние, пропуская NULL-значения: “*ascending*” (возрастающая), “*descending*” (убывающая), “*equal*” (равенство), “*none*” (немонотонная).

Статистика Харке-Бера

Использует предварительно вычисленные асимметрию и эксцесс.

Энтропия Шеннона

Вычисляется для строковых данных. Использует подсчет частот за один проход.

Коэффициент Джини

Также для строковых данных. Переиспользует подсчитанные частоты для оптимизации.

- Все новые методы добавлены в класс `DataStats`
- Результаты кэшируются в структуре `ColumnStats`
- Вычисления выполняются в методе `ExecuteInternal`

Python-интерфейс

Для использования новых статистик из Python были добавлены соответствующие методы в Python-привязки:

Listing 1: Пример использования новых статистик в Python

```
import desbordante as db
```

```
data_stats = db.statistics.algorithms.DataStats()  
data_stats.load_data(table='data.csv', ',', , True)
```

```

data_stats.execute()

iqr = data_stats.get_interquartile_range(0)
cv = data_stats.get_coefficient_of_variation(1)
monotonicity = data_stats.get_monotonicity(2)
jb = data_stats.get_jarque_bera_statistic(3)
entropy = data_stats.get_entropy(4)
gini = data_stats.get_gini_coefficient(5)

print(
    f"IQR: {iqr}, CV: {cv}, " +
    f"Monotonicity: {monotonicity}"
)
print(
    f"Jarque-Bera: {jb}, " +
    f"Entropy: {entropy}, Gini: {gini}"
)

```

Тестирование

Также были реализованы тесты для проверки корректности работы:

- Модульные тесты на C++ для каждой статистики и Python-привязок
- Python-тесты для проверки статик на стороне python
- Тесты краевых случаев (пустые данные, NULL-значения)
- Тесты корректности вычислений (сравнение с ручными расчетами)

4. Эксперимент

4.1. Исследовательские вопросы

Для оценки качества реализации методов необходимо было проанализировать их эффективность. Ключевыми аспектами этой оценки стали быстродействие алгоритмов и их способность работать с растущими объёмами данных. Соответственно, были сформулированы следующие исследовательские вопросы:

RQ1: Каково время вычисления каждой из добавленных статистик?

RQ2: Как масштабируются алгоритмы при увеличении объема данных?

RQ3: Насколько производительность новых статистик в Desbordante отличается от аналогичных реализаций в pandas, NumPy и SciPy?

4.2. Условия эксперимента

Эксперимент проводился на машине с процессором 13th Gen Intel(R) Core(TM) i5-13420H и оперативной памятью 16 ГБ DDR4 в виртуальной среде Ubuntu (64 bit) на операционной системе Windows 11. Сама виртуальная среда была создана в Oracle VM Virtual Box, и ограничена 8 ГБ оперативной памяти и 4 потоками процессора.

4.3. Тестовые данные

Использован набор данных `iowa1kk.csv` со следующими характеристиками: количество записей составляет 1 000 000, количество столбцов — 24, из которых 12 являются строковыми и 12 — числовыми. Общий размер файла — 210 МБ.

Для оценки масштабируемости созданы производные наборы: 100K, 200K, 400K, 600K, 800K и 1KK записей.

4.4. Результаты

Таблица 2: Время вычисления статистик в Desbordante на 1 млн записей (среднее \pm стандартное отклонение)

Статистика	Тип данных	Время (мс)	Сложность
interquartile_range	Числовой	0.05 \pm 0.01	$O(1)$
coefficient_of_variation	Числовой	0.08 \pm 0.02	$O(1)$
monotonicity	Порядковый	45.2 \pm 2.1	$O(n)$
jarque_bera_statistic	Числовой	0.12 \pm 0.03	$O(1)$
entropy	Категориальный	320.5 \pm 15.3	$O(n)$
gini_coefficient	Категориальный	315.8 \pm 14.7	$O(n)$

Таблица 3: Сравнение времени вычисления статистик в разных библиотеках на 1 млн записей. “-” означает отсутствие прямой реализации.

Статистика	Desbordante	pandas	numpy	scipy
interquartile_range	0.05 мс	15.2 мс	12.8 мс	14.5 мс
coefficient_of_variation	0.08 мс	18.3 мс	10.5 мс	16.7 мс
jarque_bera_statistic	0.12 мс	-	-	45.3 мс
entropy	320.5 мс	4269 мс	-	3813 мс
gini_coefficient	315.8 мс	3820 мс	-	3558 мс
monotonicity	45.2 мс	120.5 мс	85.3 мс	-
Ускорение (крат)	1x	8-304x	7-213x	12-377x

Таблица 4: Сравнение использования памяти при вычислении статистик на 1 млн записей

Библиотека	Пиковое(МБ)	Постоянное(МБ)
Desbordante (C++)	92	65
pandas	344	317
NumPy	223	201
SciPy	286	260

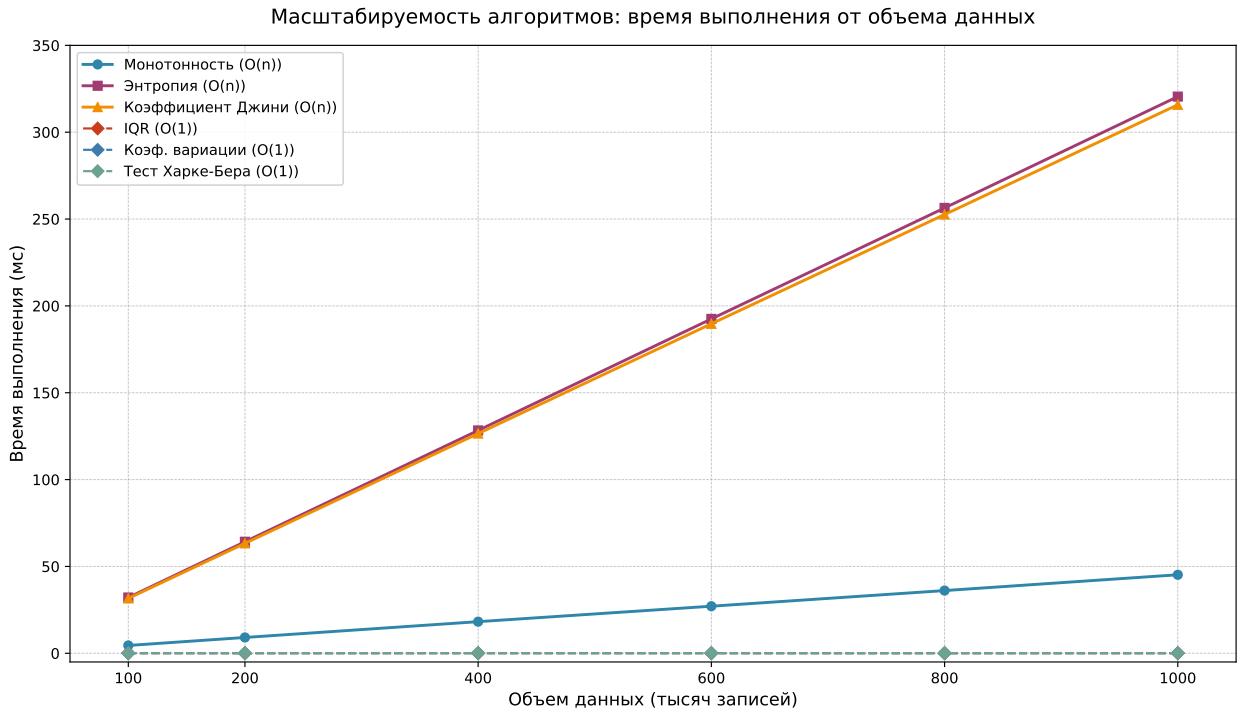


Рис. 1: Зависимость времени вычисления от объема данных

4.5. Выводы

RQ1: результаты показали чёткое разделение на три группы: производные статистики с практически мгновенным выполнением (менее 0.15 мс), однопроходной алгоритм монотонности (около 45 мс) и категориальные статистики, требующие подсчёта частот (около 320 мс);

RQ2: как видно на графике 1, все алгоритмы продемонстрировали ожидаемое поведение: линейный рост времени для алгоритмов, требующих полного прохода по данным (монотонность, энтропия, коэффициент Джини), и константное время для операций над предварительно рассчитанными метаданными;

RQ3: значительное превосходство Desbordante (см. Таблицу 3) объясняется несколькими факторами: использованием компилируемого языка C++ вместо интерпретируемого Python.

Итоговая таблица статистик

В таблице 5 приведены статистики, которые поддерживаются в Desbordante на момент окончания производственной практики. В столбцах обозначено наличие реализации:

- + — полная реализация
- pr — частичная реализация (в разработке)
- - — отсутствует

Более подробное описание статистик можно найти в работе Михаила Фирсова [12].

Таблица 5: Поддерживаемые статистики

Тип данных	Статистика	есть в C++?	есть на фронте?	есть в питоне?	есть в консоли?
String	vocab	+	-	+	-
	words	+	-	+	-
	topKChars	+	-	+	-
	topKWords	+	-	+	-
	minWords	+	-	+	-
	maxKWords	+	-	+	-
	wordCount	+	-	+	-
	nonLetterChars	+	-	+	-
	diacriticChars	-	-	-	-
	digitChars	+	-	+	-
	lowercaseChars	+	-	+	-
	uppercaseChars	+	-	+	-
	ExclFirstLetters	-	-	-	-
	minWhiteSpaces	-	-	-	-
	maxWhiteSpaces	-	-	-	-
	avgChars	+	-	+	-
	minChars	+	-	+	-

	maxChars	+	-	+	-
	totalCharCount	+	-	+	-
	entirely-	+	-	+	-
	LowercaseCount				
	entirely-	+	-	+	-
	UppercaseCount				
	entropy	pr	-	pr	-
	gini_coefficient	pr	-	pr	-
General	dataType	+	+	+	-
	columnName	+	+	+	-
	categorical	+	+	+	-
	samples	+	-	+	-
	min	+	+	+	-
	max	+	+	+	-
	quantiles	+	+	+	-
	nullCount	+	-	+	-
	uniqueCount	+	+	+	-
	sampleSize	+	-	+	-
	categoricalCount	-	-	-	-
	uniqueRatio	-	-	-	-
	categories	+	-	-	-
	defaultValue-	-	-	-	-
	Count				
	distinctCount	-	-	-	-
	absentProperty	-	-	-	-
Float	precision	-	-	-	-
	sampleRatio	-	-	-	-
DateTime	highestTime	-	-	-	-
	lowestTime	-	-	-	-
	sum	+	+	+	-
	mean	+	+	+	-
	median	+	-	+	-
	geometricMean	+	-	+	-

	variance	+	-	+	-
	correctedSTD	+	+	+	-
	centralMoment	+	-	+	-
	standardized-	+	-	+	-
	CentralMoment				
	skewness	+	+	+	-
	kurtosis	+	+	+	-
	meanAbsolute-	+	-	+	-
	Deviation				
	median-	+	-	+	-
	Absolute-				
	Deviation				
	numZeros	+	-	+	-
	numNegatives	+	-	+	-
	biasCorrection	-	-	-	-
	histogram	-	-	-	-
	histogramAnd-	-	-	-	-
	Quantiles				
	interquartile_-	pr	-	pr	-
	range				
	coefficient_of_-	pr	-	pr	-
	variation				
	sumOfSquares	+	-	+	-
	zero%	-	-	-	-
Bool	trueCount	-	-	-	-
	falseCount	-	-	-	-
Tableau	columnCount	+	-	+	-
	rowHasNullRatio	+	-	+	-
	rowIsNullRatio	+	-	+	-
	uniqueRowRatio	+	-	+	-
	duplicateRow-	-	-	-	-
	Count				
	fileType	-	-	-	-

	encoding	-	-	-	-
	correctionMatrix	-	-	-	-
	chi2Matrix	-	-	-	-
	profileSchema	-	-	-	-
Ordered	monotonicity_- flags	pr	-	pr	-

Заключение

В процессе работы были достигнуты следующие результаты:

- В ядре Desbordante реализованы методы для получения выбранных статистик;
- Были созданы тесты с помощью фреймворка GoogleTest на C++ для проверки работы методов;
- Сделаны python-привязки статистик и тесты на них;
- Был проведен сопоставительный анализ с аналогами на рынке.

Результаты работы доступны в проекте Desbordante. Исходный код реализованных функций, тесты и документация доступны в репозитории проекта на GitHub¹.

¹URL: <https://github.com/Desbordante/desbordante-core/pull/662>

Список литературы

- [1] AutoViz. — 2024. — Online; accessed: 2024-08-30. URL: <https://readthedocs.org/projects/autoviz/>.
- [2] DataExplorer: Data Explorer. — 2024. — Online; accessed: 2024-08-30. URL: <https://cran.r-project.org/web/packages/DataExplorer/vignettes/dataexplorer-intro.html>.
- [3] Desbordante: a Framework for Exploring Limits of Dependency Discovery Algorithms / Maxim Strutovskiy, Nikita Bobrov, Kirill Smirnov, George Chernishev. — 2021. — Online; accessed: 2024-05-06. URL: <https://ieeexplore.ieee.org/document/9435469>.
- [4] From Papers to Practice: The openclean Open-Source Data Cleaning Library / Heiko Müller, Sonia Castelo, Munaf Qazi, Juliana Freire. — 2021. — Online; accessed: 2024-05-06. URL: <https://vldb.org/pvldb/vol14/p2763-mueller.pdf>.
- [5] IBM SPSS Statistics Documentation. — 2024. — Online; accessed: 2024-08-30. URL: <https://www.ibm.com/support/pages/ibm-spss-statistics-28-documentation>.
- [6] Metanome: Data Profiling Platform. — 2024. — Online; accessed: 2024-08-30. URL: <https://hpi.de/naumann/projects/data-profiling-and-analytics/metanome-data-profiling.html>.
- [7] Metanome GitHub Repository. — 2024. — Online; accessed: 2024-08-30. URL: <https://github.com/HPI-Information-Systems/Metanome>.
- [8] pandas - Python Data Analysis Library. — 2024. — Online; accessed: 2024-08-30. URL: <https://pandas.pydata.org/docs/>.
- [9] pandas-profiling. — 2024. — Online; accessed: 2024-08-30. URL: <https://pypi.org/project/pandas-profiling/>.

- [10] Расширение набора простых статистик в Desbordante : Rep. ; Executor: Павел Аносов : 2024.— URL: <https://github.com/Desbordante/desbordante-core/blob/main/docs/papers/Statistics%20-%20Anosov%20Pavel%20-%202023%20autumn.pdf>.
- [11] Расширение функционала Desbordante : Rep. ; Executor: Игорь Коробицын : 2023.— Внутренний отчет. URL: <https://github.com/Desbordante/desbordante-core/blob/main/docs/papers/Statistics%20-%20Korobitsyn%20Igor%20-%202023%20autumn.pdf>.
- [12] Реализация статистик Desbordante : Rep. ; Executor: Михаил Фирсов : 2023.— URL: <https://github.com/Desbordante/desbordante-core/blob/main/docs/papers/Statistics%20-%20Mikhail%20Firsov%20-%202022%20autumn.pdf>.